

QA Automatizado con AI-as-a-Judge

Checkpoint_Modulo8_BustosRaiz_Lautaro


Capa de supervisión sobre el Agente RAG de Electromundo (rag_conocimiento_bustosraiz_lautaro.json)

Lautaro Bustos Raiz

Este tp agrega una capa de control de calidad automatizado (AI-as-a-Judge) sobre el agente de soporte con RAG construido en los módulos anteriores. Un sub-workflow supervisor (SUPERVISOR_Judge) audita cada respuesta antes de que llegue al cliente, con tres rutas de decisión: aceptar, corregir automáticamente (self-healing) o escalar a un humano.

Bloque 1 Supervisor y Rúbrica del Juez en JSON

Arquitectura



Decisión de diseño: en vez del nodo AI Agent nativo de n8n, el Juez se implementó como un HTTP Request directo a la API de Groq con `response_format: json_schema` (el mismo proveedor ya usado para Whisper STT y TTS en el Checkpoint 6). Esto fuerza al modelo a devolver exactamente el schema definido, evitando el error que advierte la unidad: “Juez con respuesta en texto libre rompe el nodo Switch”. Como red de seguridad adicional, un nodo Code posterior valida el JSON recibido y, si algo no matchea el schema esperado, fuerza el veredicto a RECHAZADO en vez de dejar pasar un dato inválido (fail-safe: nunca se acepta por error de parseo).

Insumos que recibe el Juez

A diferencia del contexto genérico sugerido por la consigna (Airtable), este proyecto recupera el contexto real desde Supabase la misma base vectorial que usa el Agente mediante una consulta directa (no la del tool-calling interno del agente), para asegurar que el Juez evalúe contra el contexto efectivamente disponible en el momento de responder:

- query original del usuario (pregunta)

- contexto recuperado de Supabase (contexto_recuperado)
- respuesta propuesta por el Agente RAG (respuesta_agente)

System Prompt del Juez (transcripción completa)

```
ROL:
Sos el Juez de Calidad (AI-as-a-Judge) que supervisa las respuestas del
Agente RAG de Electromundo. Tu única función es auditar la respuesta ya
generada; nunca la generarás, corregís ni completás vos mismo.

INSUMOS QUE RECIBÍS (JSON):
{ "pregunta": string, "contexto_recuperado": string, "respuesta_agente": string }

CRITERIO DE EVALUACIÓN – Exactitud Factual (escala 1 a 5):
- 5: la respuesta está sustentada palabra por palabra por el
  contexto_recuperado, cita la sección correcta y no agrega ningún dato
  que no esté en el contexto.
- 4: la respuesta es correcta y está sustentada, pero la cita de sección
  es imprecisa o falta una aclaración menor.
- 3: la respuesta es parcialmente correcta pero mezcla información de dos
  fragmentos distintos, o la cita no corresponde al fragmento correcto.
- 2: la respuesta contradice el contexto_recuperado en al menos un dato
  relevante (número, plazo o condición).
- 1: la respuesta inventa una política que no existe en el
  contexto_recuperado, o responde con seguridad sin tener contexto de
  respaldo.

REGLA ESPECIAL: si contexto_recuperado está vacío y la respuesta no es la
frase de escape "No sé: no figura en la documentación disponible.", la
exactitud_factual nunca puede ser mayor a 2.

MAPEO OBLIGATORIO exactitud_factual → estado_veredicto:
- 4 o 5 → "ACEPTADO"
- 2 o 3 → "CORREGIR"
- 1 → "RECHAZADO"

FORMATO DE SALIDA OBLIGATORIO:
Respondé ÚNICAMENTE con un objeto JSON válido, sin texto adicional, sin
markdown, con exactamente estos dos campos:
{ "exactitud_factual": <entero 1-5>, "estado_veredicto": "ACEPTADO" | "CORREGIR" | "RECHAZADO" }
```

Esquema JSON forzado (response_format: json_schema)

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": { "type": "integer", "minimum": 1, "maximum": 5 },
    "estado_veredicto": {
      "type": "string",
      "enum": ["ACEPTADO", "CORREGIR", "RECHAZADO"]
    }
  },
  "required": ["exactitud_factual", "estado_veredicto"],
  "additionalProperties": false
}
```

Las 3 rutas del Switch y sus umbrales

Ruta	Umbral	Acción
ACEPTADO	exactitud_factual ≥ 4	Se loguea en Airtable (tabla QA_Auditoria) y sigue al contrato de salida normal (Telegram texto o voz, según el origen).
CORREGIR (Self-Healing)	exactitud_factual 2-3	Se arma un mensaje de crítica con el motivo y se reintenta contra el mismo AI Agent RAG, con un contador que limita a 2 reintentos como máximo. Si se agotan los 2 reintentos sin llegar a ACEPTADO, se escala automáticamente como RECHAZADO.

Ruta	Umbral	Acción
RECHAZADO	exactitud_factual = 1 (o self-healing agotado)	Se envía una alerta interactiva a Slack con botones “Aprobar” y “Editar”, y la ejecución se pausa con un nodo Wait for Webhook hasta que un humano responda. La decisión final se loguea en Airtable.




Figura 2. Canvas completo del workflow corriendo en n8n, con las 3 rutas del Switch (Aceptado / Corregir / Rechazado) y todo el pipeline de voz del Checkpoint 6 integrado.

Bloque 2 Matriz de Datos A/B (10 corridas)

Arquitecturas comparadas

- Arquitectura A (actual): AI Agent RAG con Ollama Chat Model (modelo local, gratuito) + Ollama Embeddings (nomic-embed-text) para la búsqueda en Supabase.
- Arquitectura B (variante): el mismo Agente, el mismo Vector Store y el mismo embedding (Ollama, nomic-embed-text) se reemplaza únicamente el modelo de razonamiento del Agente por Groq (openai/gpt-oss-safeguard-20b). Se evaluó también migrar el embedding a OpenAI, pero se descartó: hubiera cambiado dos variables a la vez (modelo de razonamiento + embedding) y además requería recrear la tabla de Supabase con otra dimensión de vector (1536 en vez de 768), agregando una variable de confusión innecesaria al experimento.

Se aísla una sola variable (el modelo de razonamiento) para que la comparación sea válida: si cambiáramos embeddings y modelo a la vez, no sabríamos a cuál de los dos atribuir la diferencia de precisión.

Golden Dataset (5 casos, incluye 1 edge case)

#	Pregunta	Ground truth esperado
1	¿Cuánto dura la garantía de un teclado?	6 meses (producto pequeño, defectos de fabricación en hardware — Sección 2.2).
2	Usé mi notebook una semana y no me convenció, ¿la puedo devolver?	No: la devolución por satisfacción exige que el producto esté sellado y sin uso (Sección 2.1); haberla usado una semana incumple la condición, independientemente del plazo de 14 días.
3	¿Hacen envíos a Chile?	No, Electromundo solo envía dentro del territorio nacional (FAQ Envíos).
4	Se me cayó el monitor y se rompió la pantalla, ¿lo cubre la garantía?	No: los daños por golpes están explícitamente excluidos de la garantía de fábrica (Sección 2.2).
5 (edge case)	¿Tienen delivery con drones?	No figura en la documentación disponible — el agente debe responder con la frase de escape, no inventar.

Tabla de resultados — 5 corridas A + 5 corridas B

A completar ejecutando el Golden Dataset contra ambas arquitecturas en n8n (Executions → ver tokens, latencia y veredicto del Juez para cada corrida). El score_juez sale directo del campo exactitud_factual que devuelve SUPERVISOR_Judge.

Arq.	Caso	Score Juez (1-5)	¿Correcto? (vs. ground truth)	Tokens (Agente+Juez)	Latencia total (s)	Costo estimado	HI TL
A	1 — Teclado	5	Sí (reconoce ambigüedad de categoría, cita bien)	3271	16.30	\$0.0002	No
A	2 — Notebook	4	Sí (cita imprecisa)	3579	16.85	\$0.0002	No
A	3 — Envíos Chile	1	No — dijo “No sé” con contexto disponible	2790	18.38	\$0.0001	Sí
A	4 — Monitor roto	5	Sí	3417	15.56	\$0.0001	No
A	5 — Drones (edge)	5	Sí	2751	3.09	\$0.0001	No
B	1 — Teclado	1	No — dijo “No sé” con contexto disponible	2942	0.72	\$0.0005	Sí
B	2 — Notebook	4 (Juez ACEPTÓ)	NO — el Juez se equivocó (ver nota)	3869	1.31	\$0.0006	No
B	3 — Envíos Chile	5	Sí	2765	0.78	\$0.0004	No
B	4 — Monitor roto	4	Sí (cita imprecisa)	3250	1.48	\$0.0005	No
B	5 — Drones (edge)	5	Sí	2750	0.80	\$0.0005	No

Tokens y latencia de la Arquitectura B ya son la suma completa: Agente (nodo ‘OpenAI Chat Model’ en n8n, mismo patrón del router de Checkpoint 4, apuntando a openai/gpt-oss-safeguard-20b servido por Groq) + Juez (Groq openai/gpt-oss-20b). El costo del tramo del Agente es una estimación (Groq no publica un desglose prompt/completion en el token count agregado que reporta n8n para nodos LangChain, así que se aplicó la tarifa promedio publicada de gpt-oss-20b, \$0.075/\$0.30 por millón de tokens input/output, asumiendo la misma tarifa para la variante safeguard).

Hallazgo adicional Caso 1 (Teclado), falla de formulación de consulta: en la Arquitectura B, la herramienta de recuperación que usa el propio Agente respondió “Lo siento, no dispongo de información sobre la garantía de los teclados en este momento” porque el Agente le mandó a la herramienta la consulta “garantee teclado” (mezclando inglés y español) en vez de una pregunta clara en español. La misma base vectorial, consultada directamente por ‘Recuperar Contexto (para Juez)’ con el texto original del usuario, sí encontró la respuesta correcta. La causa de la falla no fue el contenido de la base de conocimiento sino cómo el Agente formuló su propia sub-consulta a la herramienta.

Hallazgo crítico Caso 2 (Notebook), falso positivo del Juez: el Agente de la Arquitectura B respondió “Sí, puedes devolverla” citando correctamente el plazo de 14 días y la condición de “sin uso”... pero ignorando que el propio usuario dijo haber usado la notebook una semana, lo cual la descalifica según esa misma condición. La respuesta correcta era negar la devolución. El Juez calificó esto con exactitud_factual 4 (ACEPTADO) porque su rúbrica actual solo verifica que los datos citados estén respaldados por el contexto no verifica que la conclusión del Agente aplique correctamente esas condiciones al caso puntual del usuario. Es un falso positivo real de la capa de QA, y confirma que debemos auditar periódicamente con una muestra revisada por humanos.

Evidencia de ejecución real

Las 10 corridas del Golden Dataset no se simularon: se enviaron como mensajes reales al bot de Telegram (Arquitectura A) y quedaron registradas automáticamente en la tabla QA_Auditoria de Airtable por el nodo Log del Switch, en el mismo formato que se usó para completar las tablas de este informe.




Figura 3. Conversación real en Telegram con las 5 preguntas del Golden Dataset — incluye los dos “No sé” de los casos 1 (teclado) y 3 (Chile) que después el Juez marcó como RECHAZADO.

6	telegram_8919733480	¿Hacen envíos a Chile?	No, no realizamos envíos ...	5.0	ACEPTADO	0.0	9/9/2026	6:35pm
7	telegram_8919733480	Se me cayó el monitor y se rompió la pa...	No, la garantía estándar n...	4.0	ACEPTADO	0.0	9/9/2026	6:40pm
8	telegram_8919733480	¿Cuánto dura la garantía de un teclado?	No sé: no figura en la doc...	1.0	RECHAZADO	0.0	9/9/2026	6:42pm
9	telegram_8919733480	Usé mi notebook una semana y no me c...	Sí, puedes devolverla. El ...	4.0	ACEPTADO	0.0	9/9/2026	6:44pm
10	telegram_8919733480	¿Tienen delivery con drones?	No sé: no figura en la doc...	5.0	ACEPTADO	0.0	9/9/2026	6:47pm
+								

Figura 4. Registro real en la tabla QA_Auditoria de Airtable (filas 6 a 10): exactitud_factual y estado_veredicto quedan logueados automáticamente por el workflow, y coinciden exactamente con los valores reportados en la Tabla de resultados del Bloque 2.




Figura 5. Sub-workflow SUPERVISOR_Judge visto desde su propia pestaña de Executions: Execute Workflow Trigger → Juez: Evaluar Respuesta (Groq) → Parsear Veredicto (Fail-Safe), con el historial de corridas reales a la izquierda.

Bloque 3 — Dashboard y Proyección Comercial

Criterio cubierto: Defensa y proyecciones comerciales.

Resumen por arquitectura

Arquitectura	Precisión según el Juez	Precisión real (vs. ground truth)	HITL Rate	Costo/ejecución	Costo × 1.000 ejec.
A — Ollama (local)	80% (4/5)	80% (4/5)	20% (1/5)	~\$0.00016	~\$0.16

Arquitectura	Precisión según el Juez	Precisión real (vs. ground truth)	HITL Rate	Costo/ejecución	Costo × 1.000 ejec.
B — Groq	80% (4/5)	60% (3/5)	20% (1/5)	~\$0.00051	~\$0.51

La columna “Precisión según el Juez” es la que muestra el sistema automáticamente (score ≥ 4). La columna “Precisión real” es la que sale de comparar cada respuesta a mano contra el ground truth del Golden Dataset. En la Arquitectura A ambas coinciden (80%). En la B no: el Juez reporta 80% pero la precisión real es 60%, porque aceptó por error la respuesta incorrecta del Caso 2 (ver Hallazgo crítico en el Bloque 2). Esto es en sí mismo el resultado más importante del experimento: un dashboard que solo mirara el veredicto del Juez habría reportado a la Arquitectura B como igual de precisa que la A, ocultando que en la práctica falla en el doble de casos.

Con el Agente ya sumado, la Arquitectura B cuesta aproximadamente $3,2\times$ más por ejecución que la A (\$0.00051 vs \$0.00016), proyectado a \$0.51 contra \$0.16 cada 1.000 ejecuciones. La diferencia es chica en términos absolutos a este volumen, pero la tendencia es clara: B es a la vez más cara y menos precisa en la práctica.

Categorías de error más frecuentes

A completar según lo que se observe en las 10 corridas. Categorías esperables a partir del diseño del Golden Dataset (ver Bloque 2):

- Falso positivo del Juez (hallazgo más crítico, Arquitectura B): el Juez aceptó una respuesta que contradice el ground truth porque solo verificó que los datos citados existieran en el contexto, sin verificar que la conclusión aplicara correctamente esas condiciones al caso del usuario. Es una falla de la capa de QA en sí misma, no solo del Agente motiva agregar a la rúbrica del Juez un chequeo explícito de “¿la conclusión es consistente con los hechos particulares que dio el usuario?”, no solo “¿los datos citados existen en el contexto?”.
- Falso “No sé” (persiste en ambas arquitecturas): tanto A como B fallaron el caso de garantía del teclado o de envíos a Chile respondiendo la frase de escape a pesar de que el contexto tenía la respuesta. Es la falla más frecuente y la más costosa: el modelo es demasiado conservador en vez de alucinar de más.
- Inconsistencia entre corridas del modelo local (Arquitectura A): el caso del teclado falló una vez con “No sé” y al reintentar la misma pregunta sin cambiar nada, el Agente respondió correctamente. Sin temperatura fijada, la misma entrada puede dar resultados distintos entre corridas un riesgo de confiabilidad propio de Ollama.
- Cita imprecisa: responder correctamente pero con una referencia de sección poco exacta (aparece en ambas arquitecturas, casos de notebook y monitor).

Recomendación comercial

Elijo mantener la Arquitectura A (Ollama local) como base de producción, y no adoptar la B por ahora. A paridad de precisión reportada por el Juez (80% en ambas), la precisión real medida contra el ground truth es 80% en A contra apenas 60% en B la mitad de las fallas de B no se ven porque el propio Juez las dejó pasar. Además, B sale aproximadamente $3,2\times$ más cara por ejecución (\$0.00051 vs \$0.00016; $\approx \$0.51$ vs $\approx \$0.16$ cada 1.000 ejecuciones). No hay ningún eje ni calidad real, ni costo en el que la Arquitectura B le gane a la A en esta ronda de pruebas. Antes de reconsiderar Groq como modelo de razonamiento, el paso obligatorio es corregir la rúbrica del Juez (agregar el chequeo de consistencia lógica entre la conclusión y los hechos del usuario) de lo contrario, cualquier comparación A/B futura seguirá estando sesgada por un supervisor que no detecta este tipo de error.